

Algoritmos Paralelos Matriciales en Ingeniería
Master en Computación Paralela y Distribuida

OPTIMIZACIÓN

OPTIMIZACIÓN

Introducción

Planteamiento del problema general:

Dada una función $f(x)$

$$f: \mathbb{R}^n \longrightarrow \mathbb{R}$$

Hallar $x=(x_1, \dots, x_n)^T$ de forma que $f(x)$ es un mínimo de la función f

Maximizar $f(x)$  Minimizar $-f(x)$

OPTIMIZACIÓN

Introducción

Problema con restricciones:

Minimizar $f(x)$ sujeto a:

$$G_i(x) \geq 0; i=1, \dots, m_d$$

$$G_i(x) = 0; i= m_d+1, \dots, m_i$$

$$x_l \leq x \leq x_u$$

OPTIMIZACIÓN


Minimización en 1 variable

Dada una función $f(x)$

$$f: \mathcal{R} \longrightarrow \mathcal{R}$$

, hallar el mínimo: $f'(x)=0$, $f''(x)>0$

MÍNIMO LOCAL



OPTIMIZACIÓN

Minimización multidimensional (sin restricciones)

Dada una función $f(\mathbf{x})$

$$f: \mathbb{R}^n \longrightarrow \mathbb{R}$$

$$\text{Gradiente: } \nabla f(\mathbf{x}) = \frac{\partial f}{\partial x_i} = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_N} \end{pmatrix}$$

$$\text{Hessiano: } H(\mathbf{x}) = \frac{\partial^2 f}{\partial x_i \partial x_j} = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1 \partial x_1} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2 \partial x_2} & & \\ \vdots & & \ddots & \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & & & \frac{\partial^2 f}{\partial x_n \partial x_n} \end{pmatrix}$$

OPTIMIZACIÓN

Minimización multidimensional (introducción)

Dada una función $f(x)$

$$f: \Omega \longrightarrow \mathbb{R}, \quad \Omega \subset \mathbb{R}^n$$

Proposición (Condición necesaria de primer orden): Si \bar{x} es un punto interior de Ω , y es un mínimo local de f en Ω , se cumple que $\nabla f(\bar{x}) = 0$.

OPTIMIZACIÓN

Minimización multidimensional (introducción)

Condiciones suficientes de segundo orden:

Proposición (Condiciones suficientes de segundo orden):

Si $f \in C^2$ está definida en Ω , donde \bar{x} es un punto interior, y además se cumple que:

- 1) $\nabla f(\bar{x}) = 0$
- 2) La matriz Hessiana $\nabla^2 f(\bar{x})$ es definida positiva

Entonces \bar{x} es un mínimo local estricto de f

OPTIMIZACIÓN

Métodos QUASI-Newton (Métrica variable)

Por la condición de primer orden, en el mínimo \mathbf{x}^* se tiene que cumplir:

$$\nabla \mathbf{f}(\mathbf{x}^*) = \mathbf{0}$$

Utilizando el método de Newton para resolver el sistema de ecuaciones no lineales $\nabla f(x) = 0$, obtendríamos $x^{(k+1)}$ resolviendo el sistema de ecuaciones lineales:

$$A \cdot \Delta x = -\nabla f(x^{(k)})$$

Siendo $A = \nabla^2 f(x^{(k)})$ Matriz Hessiana de $f(x)$

Y actualizando $x^{(k)}$:

$$x^{(k+1)} = x^{(k)} + \Delta x$$

OPTIMIZACIÓN

Métodos QUASI-Newton (Métrica variable)

Problema 1: El método de Newton necesita tanto el cálculo del Hessiano como su factorización en cada iteración.

Problema 2: Dependiendo del valor de la aproximación inicial $x^{(0)}$, el método de Newton podría llevarnos a un máximo o a un punto de silla.

Necesitamos ir en direcciones \mathbf{p} (que “desciendan” hacia el mínimo de f). Estas direcciones son las que cumplen:

$$\mathbf{p}^T \cdot \nabla f < 0 \Rightarrow \left(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} \right)^T \cdot \nabla f < 0$$

OPTIMIZACIÓN

Métodos QUASI-Newton (Métrica variable)

En el caso del método de Newton tenemos:

$$\nabla f = -A \cdot (x^{(k+1)} - x^{(k)})$$



$$(x^{(k+1)} - x^{(k)})^T \nabla f = -(x^{(k+1)} - x^{(k)})^T A \cdot (x^{(k+1)} - x^{(k)}) < 0$$



Para que la dirección sea de “descenso”, la matriz Hessiana A debe ser **definida positiva**. Así garantizamos que vamos hacia un mínimo (En el método de Newton, esto no está garantizado).